

Tối ưu hoá log-loss bằng các thuật toán gradient

Santander Product Recommendation

Nhóm ...

October 2, 2026

1. Dữ liệu

- ▶ Kaggle *Santander Product Recommendation*: hồ sơ khách hàng + 24 sản phẩm ngân hàng, theo tháng.
- ▶ Bài toán: khách có **mua thêm** sản phẩm ở tháng t không?

$$y = 1[\text{có ở } t] \cdot 1[\text{chưa có ở } t - 1]$$

- ▶ Lấy mẫu **1/12 số khách** để huấn luyện nhẹ hơn.

Cửa sổ	2015-01 → 2016-01
Train (tháng t)	2015-06 → 2015-12
Validation	2016-01
Dòng train	466 243
Dòng validation	75 839
Tỉ lệ dương	1,22%

So thuật toán trên sản phẩm `ind_recibo_ult1`; MAP@7 trên cả 24.

1. Đặc trưng: 160 cột, theo hướng top Kaggle

Nhóm	Cột	Nội dung
Nhân khẩu học	13	tuổi, thâm niên, thu nhập, giới tính, phân khúc, kênh, ...
Sở hữu $t - 1$	24	có sản phẩm ở tháng trước không
Sở hữu $t - 2..t - 5$	96	lịch sử sở hữu 5 tháng
Thời gian	24	số tháng kể từ lần cuối có sản phẩm
Tổng hợp	3	số sản phẩm đang có, đổi phân khúc, đổi trạng thái

⇒ Chuẩn hoá $(x - \mu)/\sigma$ theo train; thêm 1 cột chặn ⇒ $d = 161$.

2. Mô hình hồi quy logistic

$$P(y = 1 \mid \mathbf{x}) = \sigma(\mathbf{x}^\top \mathbf{w}) = \frac{1}{1 + \mathbf{e}^{-\mathbf{x}^\top \mathbf{w}}}$$

$$\ell(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \left[\log(1 + \mathbf{e}^{\mathbf{x}_i^\top \mathbf{w}}) - y_i \mathbf{x}_i^\top \mathbf{w} \right]$$

$$\text{Ridge: } F = \ell + \frac{\lambda}{2} \|\mathbf{w}\|_2^2$$



$$\text{Lasso: } F = \ell + \lambda_1 \|\mathbf{w}\|_1$$

$$\nabla \ell = \frac{1}{n} \mathbf{X}^\top (\sigma(\mathbf{X}\mathbf{w}) - \mathbf{y}), \quad \nabla^2 \ell = \frac{1}{n} \mathbf{X}^\top \text{diag}(\sigma_i(1 - \sigma_i)) \mathbf{X}, \quad L = \frac{\sigma_{\max}(\mathbf{X})^2}{4n} + \lambda = 6.25$$

$\Rightarrow \lambda = \lambda_1 = 10^{-3}$; chặn không bị phạt; mọi thuật toán bắt đầu từ $\mathbf{w}_0 = 0$.

3. GD bước cố định



$$w_{k+1} = w_k - t \nabla F(w_k), \quad t \in \{0.1, 0.5, 1, 1.5, 2, 4\} \times \frac{1}{L}$$



⇒ Tốt nhất $t = 4/L$ ($F = 0.04821$): vượt ngưỡng $2/L$, dao động ~ 10 vòng đầu rồi vẫn hội tụ.

3. GD backtracking (Armijo)



$$t_k \leftarrow 2t_{k-1}, \quad t_k \leftarrow \beta t_k \text{ đến khi } F(w_k - t_k \nabla F) \leq F(w_k) - c t_k \|\nabla F\|^2$$



$\Rightarrow$ Mọi β cùng tới $F \approx 0.04363$; $\beta = 0.1$ nhanh nhất (46 s / 250 vòng), $\beta = 0.9$ chậm gấp ~ 3 lần.

3. GD tăng tốc Nesterov

$$w_{k+1} = v_k - t \nabla F(v_k), \quad v_{k+1} = w_{k+1} + \frac{\theta_k - 1}{\theta_{k+1}} (w_{k+1} - w_k), \quad \theta_{k+1} = \frac{1 + \sqrt{1 + 4\theta_k^2}}{2}$$





⇒ Cùng bước $1/L$: GD $F = 0.0671$, Nesterov $F = 0.04368$. Tốt nhất $t = 2/L$: $F = 0.04364$.

3. Newton

$$\nabla^2 F(w_k) d_k = \nabla F(w_k), \quad w_{k+1} = w_k - t_k d_k$$



bước cố định $t_k = t$, hoặc backtracking bắt đầu từ $t = 1$



⇒ Hội tụ bậc hai: $F = 0.043630$ — thấp nhất — chỉ sau 5 vòng (3,2 s).

3. SGD mini-batch



$$w_{k+1} = w_k - \alpha_k \frac{1}{B} \sum_{i \in \mathcal{B}_k} \nabla F_i(w_k), \quad B = 4096, \quad \alpha_k \in \{\alpha_0, \alpha_0/\sqrt{k}, \alpha_0/k\}$$



⇒ Loss mini-batch nên gọn. Tốt nhất $\alpha_0 = 0.2$, bước cố định; α_0/k teo quá nhanh.

3. Subgradient (Lasso)

$$s_j = \begin{cases} \nabla_{j\ell} + \lambda_1 \text{sign}(w_j) & w_j \neq 0 \\ \nabla_{j\ell} - \text{clip}(\nabla_{j\ell}, -\lambda_1, \lambda_1) & w_j = 0 \end{cases} \quad w_{k+1} = w_k - \frac{\alpha_0}{\sqrt{k+1}} s$$





⇒ Không đơn điệu, chỉ $O(1/\sqrt{k})$. Tốt nhất $\alpha_0 = 8$: $F = 0.05169$, 154/160 hệ số $\neq 0$.

3. Proximal gradient — ISTA và FISTA (Lasso)

$$\text{ISTA: } w_{k+1} = \text{prox}_{t\lambda_1 \|\cdot\|_1} (w_k - t \nabla \ell(w_k)), \quad \text{prox}(v)_j = \text{sign}(v_j) \max(|v_j| - t\lambda_1, 0)$$


$$\text{FISTA: } w_{k+1} = \text{prox}(v_k - t \nabla \ell(v_k)), \quad v_{k+1} = w_{k+1} + \frac{\theta_k - 1}{\theta_{k+1}} (w_{k+1} - w_k)$$



$\Rightarrow$ ISTA ($O(1/k)$) chưa hội tụ sau 250 vòng ($F = 0.05827$). FISTA ($O(1/k^2)$), $t = 2/L$: $F = 0.04655$ — **thấp hơn sklearn** (0.04669), 24/160 hệ số $\neq 0$.

3. So sánh best của từng thuật toán

$$k_\varepsilon = \min \left\{ k : \frac{F(w_k) - F^*}{F^*} \leq 1\% \right\}, \quad F^* = \min (F_{\text{cuối}}, F_{\text{sklearn}}) \text{ riêng cho Ridge / Lasso}$$



⇒ Newton hội tụ sau 5 vòng (3,2 s), ngang sklearn (27 vòng, 2,9 s); FISTA hội tụ sau 99 vòng. Chỉ GD bước cố định và Subgradient chưa hội tụ sau 250 vòng.

4. Logistic (thuật toán tốt nhất) so với benchmark — MAP@7

$$\text{AP@7}_i = \frac{1}{\min(|\mathbf{A}_i|, 7)} \sum_{k=1}^7 \text{Prec}_i(k) \mathbf{1}[\hat{p}_{ik} \in \mathbf{A}_i], \quad \text{MAP@7} = \frac{1}{|U|} \sum_{i \in U} \text{AP@7}_i$$

Mô hình (24 sản phẩm)	khách có thêm	toàn bộ khách	giây
Phổ biến (mốc sàn)	0.6264	0.01768	0
Logistic Ridge, Newton	0.7966	0.02249	553
LightGBM nhị phân $\times 24$	0.8087	0.02283	109
LightGBM softmax	0.8197	0.02314	11

A_i : sản phẩm khách i thực sự thêm; bỏ sản phẩm đã có ở $t - 1$ trước khi lấy top-7. Benchmark: LightGBM nhị phân $\times 24$ (hướng hạng 2 Kaggle), LightGBM softmax (hướng hạng 1).

5. Kết luận

1. **Newton** tốt nhất: $F = 0.043630$ sau 5 vòng (3,2 s); backtracking và Nesterov cũng hội tụ nhưng cần 80–95 vòng.
2. **Ngưỡng $2/L$ chỉ là trường hợp xấu nhất**: $t = 4/L$ vẫn hội tụ (sau ~ 10 vòng dao động).
3. **SGD** gọn theo mini-batch; bước cố định $\alpha_0 = 0.2$ thắng lịch giảm bước trong 42 epoch.
4. **Lasso**: ISTA và subgradient chưa hội tụ sau 250 vòng; thêm gia tốc (FISTA) là hội tụ sau 99 vòng, F thấp hơn sklearn.
5. **MAP@7**: logistic (Newton) đạt 0.7966, kém LightGBM softmax 2,3 điểm; Newton đã hội tụ nên khoảng cách nằm ở mô hình tuyến tính, không ở thuật toán tối ưu.